ĐẠI HỌC KINH TẾ QUỐC DÂN
Viện Đào tạo Tiên tiến, Chất lượng cao và POHE



BÀI TẬP NHÓM

HỌC PHẦN: KHOA HỌC DỮ LIỆU TRONG KINH TẾ VÀ KINH DOANH

NHÓM 5

***ĐỀ TÀI*: Phân tích các yếu tố liên quan đến khả năng sống sót của hành khách trong thảm kịch Titanic**

Giảng viên:	TS. TRẦN ĐỨC MINH	
Thành viên:	Ngô Quang Minh	11241082
	Đỗ Phương Thảo	11242598
	Nguyễn Hương Giang	11240476
	Vũ Khánh Thơ	11243728
	Cù Danh Đạt	11244814
Lớp chuyên ngành:	**Kinh tế Đầu tư CLC 66A**	

Mã nguồn (GitHub): https://github.com/ngoquangminh101206-rgb/Titanic-project

MỤC LỤC

TÓM TẮT ĐIỀU HÀNH **4**
GIAI ĐOẠN 1: THU THẬP VÀ ĐÁNH GIÁ DỮ LIỆU BAN ĐẦU **5**
1.1. Nguồn dữ liệu, cấu trúc và mục tiêu nghiên cứu 5
1.1. Nguồn dữ liệu và cấu trúc 5
1.2 Từ điển dữ liệu 6
Nhận xét và đánh giá giai đoạn 1 7
GIAI ĐOẠN 2: TIỀN XỬ LÝ VÀ LÀM SẠCH DỮ LIỆU **9**
2.1 Kiểm tra định dạng và dữ liệu trùng lặp 9
2.2 Phát hiện ngoại lệ (outliers) bằng phương pháp IQR 9
2.3. Xử lý giá trị khuyết thiếu 10
2.4 Tạo đặc trưng mới (Feature Engineering) 11
2.5. Mã hóa và chuẩn hóa dữ liệu 11
Nhận xét và đánh giá giai đoạn 2 11
GIAI ĐOẠN 3: PHÂN TÍCH VÀ TRỰC QUAN HÓA **13**
3.1. Hệ giả thuyết nghiên cứu và phương pháp kiểm định 13
H1 - Giới tính 14
H2 - Hạng vé (địa vị kinh tế) 15
H3 - Tuổi 15
H4 - Quy mô gia đình 18
H5 - Giá vé 19
H6 - Cảng lên tàu và biến gây nhiễu 20
Tổng hợp kết quả kiểm định giả thuyết 21
Tương tác Giới tính × Hạng vé và ma trận tương quan 22
3.2 Hồi quy logistic nhiều biến (kiểm soát đồng thời nhiều yếu tố) 23
3.3. Xây dựng mô hình dự báo cơ sở 24
Nhận xét và đánh giá giai đoạn 3 27
GIAI ĐOẠN 4: ĐÁNH GIÁ TÁC ĐỘNG VÀ KHUYẾN NGHỊ **28**
4.1. Các phát hiện chuyên môn nổi bật 28
4.2. Đánh giá tác động và hàm ý quản trị 28
4.3. Khuyến nghị ứng dụng thực tế 29
4.4. Hạn chế của nghiên cứu và hướng phát triển 30
KẾT LUẬN CHUNG **32**

DANH MỤC BẢNG

Bảng 1. Từ điển dữ liệu.....6
Bảng 2. Tổng hợp kết quả kiểm định giả thuyết.....21
Bảng 3. Kết quả đánh giá mô hình bằng Stratified 5-fold Cross Validation.....26
Bảng 4. Phát hiện từ dữ liệu, hàm ý quản trị và giới hạn diễn giải.....28

DANH MỤC HÌNH

Hình 1. Tỷ lệ giá trị khuyết thiếu theo thuộc tính (tập train).....7
Hình 2. Biểu đồ hộp phát hiện ngoại lệ của Age, Fare, SibSp, Parch.....9
Hình 3. Phân phối Fare trước và sau khi biến đổi log1p.....10
Hình 4. Phân phối Age trước và sau khi xử lý giá trị thiếu.....11
Hình 5. Tỷ lệ sống sót theo giới tính.....14
Hình 6. Tỷ lệ sống sót theo hạng vé.....15
Hình 7. Tỷ lệ sống sót theo nhóm tuổi.....16
Hình 8. Phân phối tuổi theo kết quả sống sót.....17
Hình 9. Tỷ lệ sống sót theo quy mô gia đình.....18
Hình 10. Phân phối giá vé (log1p) theo tình trạng sống sót.....19
Hình 11. Tỷ lệ sống sót theo cảng lên tàu.....20
Hình 12. Tỷ lệ sống sót (%) theo Giới tính × Hạng vé.....22
Hình 13. Ma trận tương quan giữa các biến số.....22
Hình 14. Ma trận nhầm lẫn của Random Forest (out-of-fold).....25
Hình 15. Mười hai đặc trưng quan trọng nhất theo Random Forest.....26

TÓM TẮT ĐIỀU HÀNH

Thảm kịch đắm tàu Titanic năm 1912 không chỉ là một tai nạn hàng hải bi thảm mà còn là một tập dữ liệu kinh điển trong Khoa học Dữ liệu để nghiên cứu sự bất bình đẳng xã hội, tâm lý hành vi con người và các yếu tố quyết định sự sinh tồn trong điều kiện khủng hoảng. Báo cáo này áp dụng quy trình Khoa học Dữ liệu toàn diện từ Thu thập, Làm sạch, Tiền xử lý nâng cao (Xử lý ngoại lệ thông minh, chuyển đổi phân phối biến), Phân tích khám phá (EDA) có kiểm định thống kê, cho đến việc đề xuất các khuyến nghị ứng phó rủi ro hiện đại. Kết quả chỉ ra rằng Giới tính (Sex), Hạng vé (Pclass), và Độ tuổi (Age) là ba trụ cột cốt lõi chi phối cơ hội sống sót của hành khách.

Báo cáo thực hiện quy trình khoa học dữ liệu gồm bốn giai đoạn: (1) thu thập và đánh giá dữ liệu; (2) tiền xử lý và làm sạch; (3) phân tích, kiểm định giả thuyết và trực quan hóa; (4) đánh giá tác động, đề xuất khuyến nghị và nêu giới hạn nghiên cứu.

Dữ liệu huấn luyện train.csv gồm 891 hành khách, 12 thuộc tính; dữ liệu test.csv gồm 418 hành khách, 11 thuộc tính và không có nhãn sống sót. Trong tập train, 342 người sống sót (38,38%) và 549 người không sống sót (61,62%). Ba trường thiếu đáng chú ý là Cabin (77,10%), Age (19,87%) và Embarked (0,22%).

Sau khi rà soát, nhóm không xóa các quan sát bị đánh dấu ngoại lệ chỉ dựa trên quy tắc IQR. Các giá trị Fare = 0, tuổi thập phân và mã vé dùng chung được xem xét theo ngữ cảnh. Fare được biến đổi bằng log1p, làm độ lệch giảm từ 4,787 xuống 0,395. Dữ liệu thiếu được xử lý theo bản chất từng biến; trong mô hình, các bước điền khuyết, mã hóa và chuẩn hóa được đặt trong Pipeline để hạn chế rò rỉ dữ liệu.

Kết quả phân tích cho thấy tỷ lệ sống sót quan sát được khác biệt rõ theo giới tính và hạng vé: nữ 74,2%, nam 18,9%; hạng 1 63,0%, hạng 2 47,3%, hạng 3 24,2%. Nhóm gia đình 2-4 người có tỷ lệ sống sót 57,9%, cao hơn nhóm đi một mình (30,4%) và nhóm gia đình từ 5 người (16,1%). Với tuổi, kiểm định chính trên 714 quan sát có tuổi gốc cho kết quả Chi-square $p = 0,0138$, trong khi Mann-Whitney $p = 0,160$; hai kiểm định trả lời hai câu hỏi thống kê khác nhau.

Trong kiểm định chéo phân tầng 5-fold, Random Forest đạt Accuracy 0,834 và ROC-AUC 0,882; Logistic Regression đạt Accuracy 0,824 và ROC-AUC 0,876, đồng thời có Recall cao hơn (0,745 so với 0,716). Vì vậy, Random Forest chỉ nhỉnh hơn ở một số chỉ số, không vượt trội trên mọi tiêu chí.

Các khuyến nghị tập trung vào quy trình sơ tán dễ tiếp cận, hỗ trợ hành khách cần trợ giúp, nguyên tắc cứu hộ công bằng, quản trị dữ liệu hành khách an toàn và giới hạn việc sử dụng mô hình dự báo. Những khuyến nghị này là bài học quản trị rút ra từ dữ liệu lịch sử, không phải tác động nhân quả đã được chứng minh.

GIAI ĐOẠN 1: THU THẬP VÀ ĐÁNH GIÁ DỮ LIỆU BAN ĐẦU

1.1. Nguồn dữ liệu, cấu trúc và mục tiêu nghiên cứu

- Nguồn dữ liệu: Kaggle - Titanic: Machine Learning from Disaster.
- train.csv: 891 quan sát, 12 thuộc tính, bao gồm biến mục tiêu Survived; đây là tập dùng cho phân tích mô tả, kiểm định giả thuyết và đánh giá mô hình.
- test.csv: 418 quan sát, 11 thuộc tính, không có Survived; tập này chỉ dùng để minh họa khả năng áp dụng mô hình lên dữ liệu mới.
- gender_submission.csv: 418 dự đoán mẫu do Kaggle cung cấp; đây không phải nhãn thực tế nên không dùng để kiểm định hoặc đánh giá độ chính xác.

PassengerId là mã định danh hành khách. Nhóm kiểm tra tính duy nhất và mức độ giao nhau của mã này giữa train và test, nhưng không gộp hai tập để phân tích vì test không có nhãn Survived.

Mục tiêu nghiên cứu

1. Đánh giá cấu trúc, chất lượng và mức độ đầy đủ của dữ liệu.
2. Làm sạch dữ liệu, xử lý giá trị thiếu và tạo đặc trưng phục vụ phân tích.
3. Kiểm định các giả thuyết về mối liên hệ giữa đặc điểm hành khách và tình trạng sống sót.
4. Xây dựng, so sánh mô hình Logistic Regression và Random Forest.
5. Chuyển các phát hiện có căn cứ thành bài học quản trị an toàn hàng hải, đồng thời nêu rõ giới hạn suy luận.

Câu hỏi nghiên cứu: Những đặc điểm nào trong dữ liệu có mối liên hệ với tình trạng sống sót? Mức độ liên hệ ra sao? Các mô hình phân loại có thể dự báo kết quả ở mức nào trên dữ liệu huấn luyện được đánh giá bằng kiểm định chéo?

1.1. Nguồn dữ liệu và cấu trúc

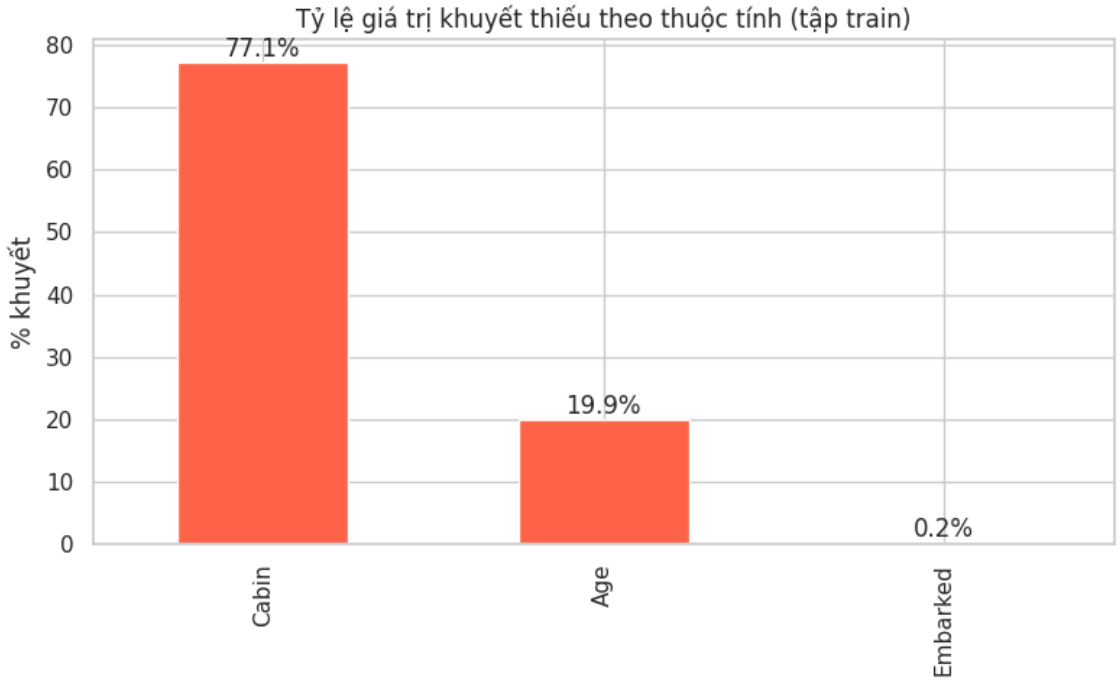
- Nguồn: Kaggle - Titanic: Machine Learning from Disaster.
- train.csv: 891 quan sát, 12 thuộc tính, bao gồm biến mục tiêu Survived.
- test.csv: 418 quan sát, 11 thuộc tính; không có Survived, được dùng để minh họa khả năng áp dụng quy trình lên dữ liệu mới.
- gender_submission.csv: 418 dòng dự đoán mẫu của Kaggle, không phải nhãn sống sót thực tế nên không dùng để kiểm định giả thuyết.

PassengerId là mã định danh. Hai tập train và test được đối chiếu bằng mã này nhưng không gộp thành một tập phân tích vì test không có nhãn Survived.

1.2 Từ điển dữ liệu

Bảng 1. Từ điển dữ liệu

Thuộc tính	**Ý nghĩa**	**Kiểu**
PassengerId	Mã hành khách (khóa chính)	Định danh
Survived	0 = tử vong, 1 = sống sót (biến mục tiêu)	Nhị phân
Pclass	Hạng vé: 1 (cao) - 3 (thấp), đại diện địa vị kinh tế	Thứ bậc
Name	Họ tên (chứa danh xưng)	Văn bản
Sex	Giới tính	Phân loại
Age	Tuổi	Liên tục
SibSp	Số anh chị em/vợ chồng đi cùng	Đếm
Parch	Số cha mẹ/con cái đi cùng	Đếm
Ticket	Số vé	Văn bản
Fare	Giá vé	Liên tục
Cabin	Số cabin	Văn bản
Embarked	Cảng lên tàu: C = Cherbourg, Q = Queenstown, S = Southampton	Phân loại



Hình 1. Tỷ lệ giá trị khuyết thiếu theo thuộc tính (tập train)

Nhận xét và đánh giá giai đoạn 1

Bộ dữ liệu được lựa chọn là Titanic: Machine Learning from Disaster trên Kaggle. Tập train.csv gồm 891 hành khách và 12 thuộc tính, trong đó Survived là biến mục tiêu; tập test.csv gồm 418 hành khách và 11 thuộc tính, không có nhãn sống sót. Vì vậy, nhóm sử dụng train cho phân tích mô tả, kiểm định giả thuyết và đánh giá mô hình; test chỉ được dùng để minh họa việc áp dụng mô hình lên dữ liệu chưa có nhãn.

Trong tập train, có 342 hành khách sống sót (38,38%) và 549 hành khách không sống sót (61,62%). Tỷ lệ này cho thấy hai lớp không cân bằng hoàn toàn, do đó khi đánh giá mô hình không nên chỉ dựa vào Accuracy mà cần xem thêm Precision, Recall, F1-score và ROC-AUC.

Kiểm tra dữ liệu cho thấy ba thuộc tính thiếu đáng chú ý trong train là Cabin (687 giá trị; 77,10%), Age (177; 19,87%) và Embarked (2; 0,22%). Các bảng profile ở trên đồng thời cung cấp kiểu dữ liệu và tỷ lệ thiếu của cả train lẫn test, giúp nhóm xác định cách xử lý phù hợp cho từng trường.

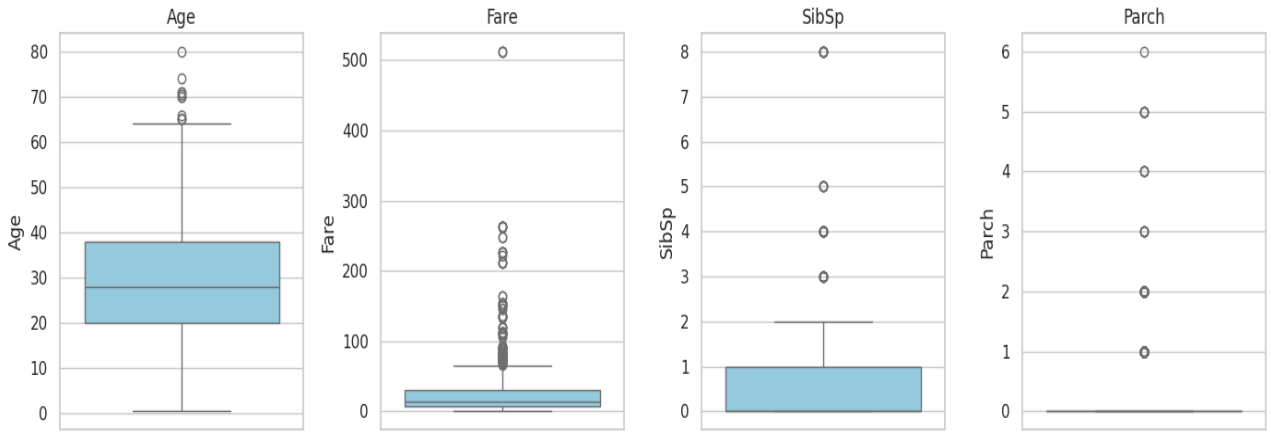
PassengerId được dùng làm mã định danh, không phải biến giải thích. Nhóm kiểm tra tính duy nhất và mức độ giao nhau giữa hai tập; không gộp train với test vì test không có Survived. Không phát hiện dòng trùng hoàn toàn trong train theo kết quả kiểm tra ban đầu.

Kết luận giai đoạn 1: dữ liệu có cấu trúc phù hợp cho bài toán phân loại nhị phân, nhưng cần xử lý dữ liệu thiếu và xem xét phân phối lệch của một số biến trước khi phân tích và xây dựng mô hình. Các kết quả kiểm định có giám sát chỉ được tính trên train.

GIAI ĐOẠN 2: TIỀN XỬ LÝ VÀ LÀM SẠCH DỮ LIỆU

2.1 Kiểm tra định dạng và dữ liệu trùng lặp

2.2 Phát hiện ngoại lệ (outliers) bằng phương pháp IQR

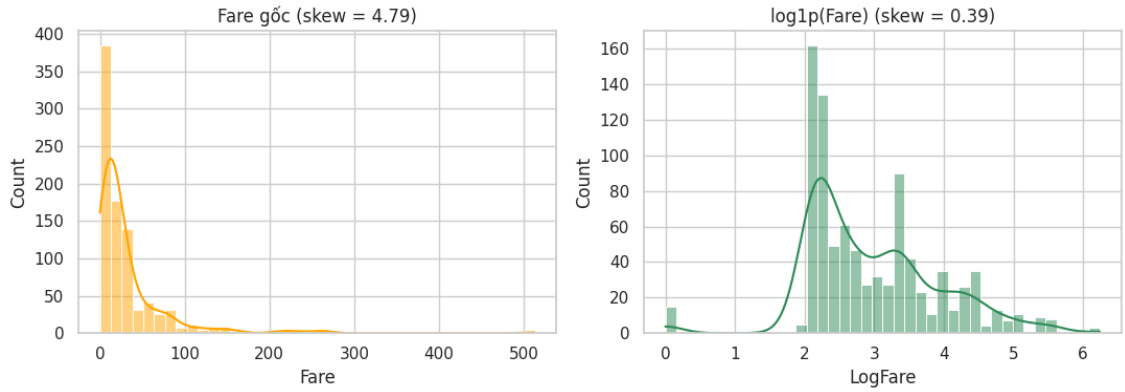


Hình 2. Biểu đồ hộp phát hiện ngoại lệ của Age, Fare, SibSp, Parch

Giải trình phát hiện và xử lý ngoại lệ: Phương pháp IQR được sử dụng để nhận diện các quan sát nằm xa phần phân phối trung tâm. Tuy nhiên, IQR chỉ là công cụ sàng lọc thống kê; một giá trị bị đánh dấu không đồng nghĩa với dữ liệu sai. Nhóm vì vậy không xóa hoặc winsorize tự động các quan sát này.

Đặc biệt, Parch có Q1 = 0 và Q3 = 0 nên IQR bằng 0. Theo quy tắc IQR, mọi giá trị dương đều bị đánh dấu là ngoại lệ. Đây là hệ quả của phân phối tập trung nhiều ở giá trị 0, không phải bằng chứng rằng tất cả các trường hợp có cha mẹ/con cái đi cùng đều sai. Tương tự, các giá trị SibSp lớn có thể phản ánh gia đình đông người.

Đối với Fare, giá trị cao nhất cần được đối chiếu với hạng vé và thông tin hành khách. Nhóm giữ lại các giá trị hợp lệ và tạo thêm LogFare = log1p(Fare) nhằm giảm độ lệch phải, giúp biểu diễn phân phối dễ đọc hơn. Những trường hợp Fare = 0 được rà soát riêng ở ô tiếp theo; không tự động thay thế nếu chưa có bằng chứng đó là lỗi ghi nhận.



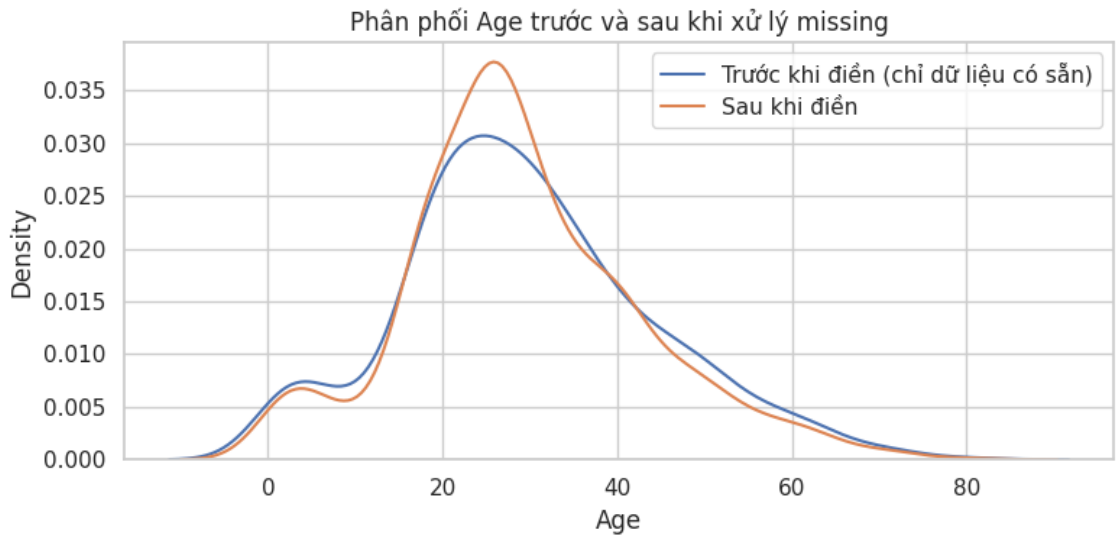
Hình 3. Phân phối Fare trước và sau khi biến đổi log1p

2.3. Xử lý giá trị khuyết thiếu

- Age: điền Median theo nhóm Title × Pclass, sau đó dự phòng bằng Median theo Title và Median toàn bộ. Cách làm theo nhóm phản ánh sự khác biệt về độ tuổi giữa các danh xưng và hạng vé; Median ít nhạy với các giá trị cực đoan hơn Mean. Đồng thời tạo Age_missing để giữ thông tin về việc tuổi ban đầu bị khuyết.
- Embarked: điền Mode vì chỉ thiếu 2/891 quan sát (0,22%) và đây là biến phân loại.
- Cabin: không tự tạo số cabin giả. Tạo Has_Cabin (có/không có thông tin cabin) và Deck (ký tự đầu của Cabin, nhóm thiếu thành U). Biến Cabin gốc được giữ trong dữ liệu ban đầu để truy vết.

Lưu ý: bước điền Age này phục vụ phân tích khám phá và trực quan hóa. Ở phần mô hình dự báo, việc điền khuyết được đặt bên trong Pipeline để mỗi fold chỉ học tham số từ phần huấn luyện của fold đó, hạn chế data leakage. Trong Pipeline, Age được điền bằng Median chung của phần training (đơn giản hơn Median theo Title × Pclass dùng ở phần khám phá), nên kết quả mô hình có thể khác nhẹ so với dữ liệu đã điền ở phần phân tích.

2.4 Tạo đặc trưng mới (Feature Engineering)



Hình 4. Phân phối Age trước và sau khi xử lý giá trị thiếu

2.5. Mã hóa và chuẩn hóa dữ liệu

- One-Hot Encoding: dùng cho Sex, Embarked, Title và Pclass. Mặc dù Pclass có thứ bậc, nhóm xử lý nó như biến phân loại trong mô hình chính để không áp đặt giả định rằng khoảng cách giữa hạng 1-2 bằng khoảng cách giữa hạng 2-3.
- StandardScaler: áp dụng cho các biến số trong Pipeline. Chuẩn hóa giúp Logistic Regression tối ưu ổn định hơn khi các biến có đơn vị và độ lớn khác nhau. Random Forest không phụ thuộc mạnh vào thang đo, nhưng dùng chung quy trình tiền xử lý để so sánh nhất quán.
- Imputation: Median cho biến số và giá trị xuất hiện nhiều nhất cho biến phân loại. Median phù hợp hơn Mean khi phân phối có lệch hoặc ngoại lệ.
- Chống Data Leakage: imputer, encoder và scaler được đặt bên trong Pipeline; chúng chỉ được fit trên phần training của từng fold, không học thông tin từ fold validation.

Các biến Deck, AgeGroup, IsAlone và FarePerPerson được tạo để hỗ trợ khám phá và diễn giải. Mô hình chính chỉ dùng một tập biến được chọn trước, tránh đưa đồng thời nhiều biến gần như trùng lặp thông tin hoặc làm tăng số chiều không cần thiết.

Nhận xét và đánh giá giai đoạn 2

Quá trình làm sạch được thực hiện trên bản sao df để bảo toàn dữ liệu gốc train. Nhóm đã rà soát định dạng các biến, giá trị âm hoặc nằm ngoài phạm vi hợp lý, dòng trùng lặp và các trường hợp có giá trị cực đoan. Mã vé xuất hiện ở nhiều hành khách không được xem là trùng lặp tự động vì có thể là vé dùng chung của gia đình hoặc nhóm.

Với dữ liệu thiếu, Age được điền bằng Median theo nhóm Title × Pclass, sau đó dùng các mức Median dự phòng nếu nhóm không có đủ dữ liệu. Cách làm này khai thác sự khác biệt về độ tuổi giữa các danh xưng và hạng vé, đồng thời ít bị kéo lệch bởi các giá trị cực đoan hơn Mean. Biến Age_missing được tạo để lưu lại thông tin ban đầu về việc thiếu tuổi. Embarked được điền bằng Mode vì chỉ thiếu 2 quan sát. Do Cabin thiếu tới 77,10%, nhóm không tự suy đoán số cabin mà tạo Has_Cabin và Deck để giữ lại phần thông tin còn quan sát được.

Phương pháp IQR cho thấy một số giá trị nằm ngoài khoảng phân vị, nhưng nhóm không loại bỏ máy móc vì các giá trị này có thể phản ánh đặc điểm thật của hành khách. Trường hợp Parch cần giải thích riêng do Q1 và Q3 đều bằng 0 khiến IQR bằng 0; vì vậy các giá trị dương bị đánh dấu theo quy tắc toán học chứ không nhất thiết là sai. Fare được biến đổi bằng log1p để giảm độ lệch phải, không phải để xóa các quan sát có giá trị cao.

Nhóm bổ sung các đặc trưng như Title, FamilySize, IsAlone, AgeGroup, Has_Cabin và FarePerPerson nhằm hỗ trợ phân tích. Không phải tất cả đặc trưng đều được đưa vào mô hình; việc lựa chọn được giới hạn để tránh thông tin trùng lặp và tăng độ phức tạp không cần thiết.

Kết luận giai đoạn 2: dữ liệu đã được xử lý theo nguyên tắc giữ lại quan sát hợp lệ, giải trình rõ lựa chọn kỹ thuật và tách biệt tiền xử lý phục vụ EDA với tiền xử lý trong Pipeline mô hình. Điều này giúp giảm nguy cơ Data Leakage khi đánh giá bằng kiểm định chéo.

GIAI ĐOẠN 3: PHÂN TÍCH VÀ TRỰC QUAN HÓA

3.1. Hệ giả thuyết nghiên cứu và phương pháp kiểm định

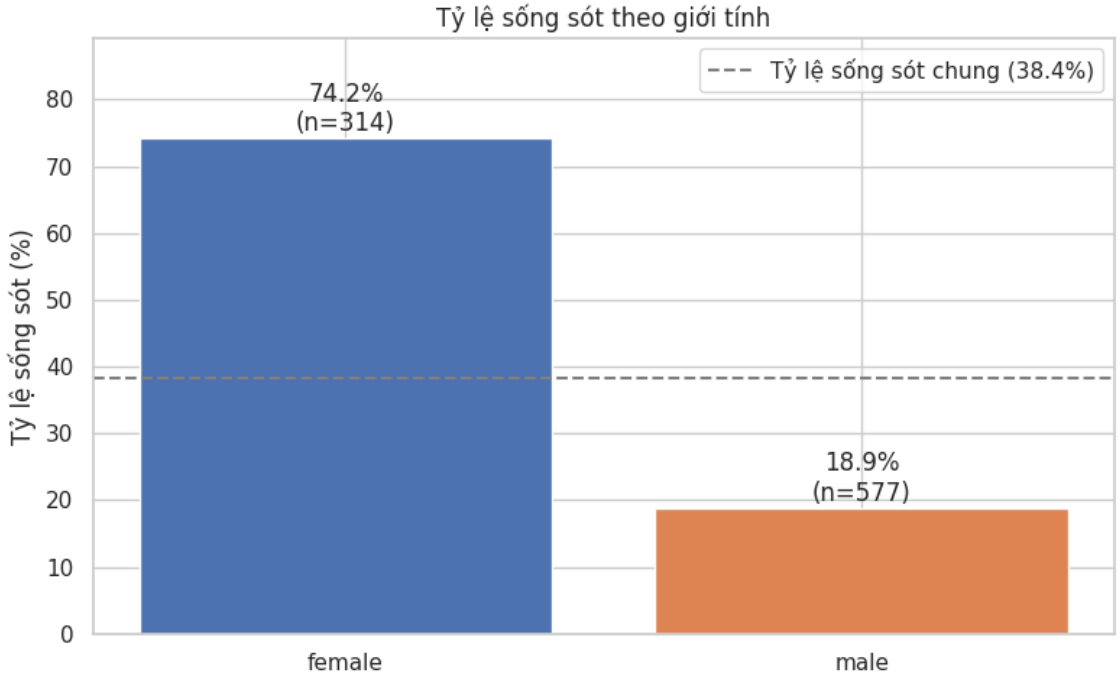
Nhóm xây dựng các giả thuyết nhằm kiểm tra mối liên hệ giữa đặc điểm hành khách và tình trạng sống sót:

- H1: Tỷ lệ sống sót khác nhau giữa nam và nữ; dự kiến nữ có tỷ lệ cao hơn.
- H2: Tỷ lệ sống sót khác nhau theo hạng vé; dự kiến hành khách hạng 1 có tỷ lệ cao hơn hạng 2 và hạng 3.
- H3: Tỷ lệ sống sót khác nhau giữa các nhóm tuổi; dự kiến trẻ em có tỷ lệ cao hơn.
- H4: Tỷ lệ sống sót khác nhau theo quy mô gia đình; dự kiến nhóm gia đình 2-4 người có tỷ lệ cao hơn nhóm đi một mình và nhóm gia đình đông.
- H5: Phân phối giá vé khác nhau giữa nhóm sống sót và không sống sót; dự kiến nhóm sống sót có giá vé cao hơn.
- H6: Tình trạng sống sót có liên hệ với cảng lên tàu; cần xem xét khả năng khác biệt này liên quan đến cơ cấu hạng vé.

Phương pháp: Chi-square được sử dụng cho các biến phân loại; Mann-Whitney U được sử dụng để so sánh phân phối biến liên tục giữa hai nhóm sống sót và tử vong, không yêu cầu giả định phân phối chuẩn. Cramér's V được báo cáo để đánh giá cỡ ảnh hưởng của kiểm định Chi-square. Mức ý nghĩa thống kê được chọn là $\alpha = 0,05$.

Các kiểm định là phân tích quan sát trên cùng một bộ dữ liệu, do đó p-value không chứng minh quan hệ nhân quả. Vì nhóm thực hiện nhiều kiểm định, các kết quả có p-value gần 0,05 cần được diễn giải thận trọng.

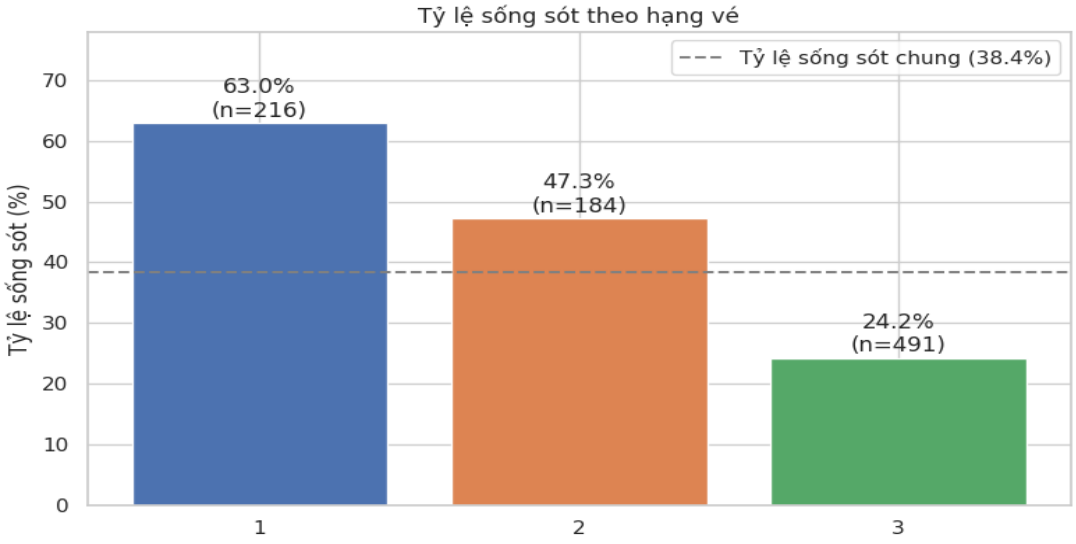
H1 - Giới tính



Hình 5. Tỷ lệ sống sót theo giới tính

Diễn giải: Tỷ lệ sống sót của nữ khoảng 74,2%, cao hơn đáng kể so với nam, khoảng 18,9%. Kiểm định Chi-square cho p-value = $1{,}20 \times 10^{-58}$ và Cramér's V = 0,54, cho thấy mối liên hệ mạnh giữa giới tính và tình trạng sống sót trong mẫu. Kết quả ủng hộ H1. Tuy nhiên, đây là mối liên hệ quan sát được, không phải bằng chứng rằng giới tính là nguyên nhân duy nhất quyết định kết quả.

H2 - Hạng vé (địa vị kinh tế)



Hình 6. Tỷ lệ sống sót theo hạng vé

Diễn giải: Tỷ lệ sống sót giảm theo hạng vé: hạng 1 khoảng 63,0%, hạng 2 khoảng 47,3% và hạng 3 khoảng 24,2%. Kiểm định Chi-square cho p-value = $4{,}55 \times 10^{-23}$, Cramér's V = 0,34. Kết quả ủng hộ H2 và cho thấy hạng vé có mối liên hệ đáng kể với khả năng sống sót. Không nên diễn giải đây là tác động nhân quả độc lập vì hạng vé có thể liên quan đến vị trí, điều kiện tiếp cận và các đặc điểm khác của hành khách.

H3 - Tuổi

Phân tích chính - dữ liệu tuổi gốc: Để tránh đưa giá trị ước lượng vào kiểm định, nhóm ưu tiên 714 quan sát có Age được ghi nhận thực tế. Các kết quả Chi-square theo nhóm tuổi và Mann-Whitney trên tuổi liên tục ở ô tiếp theo được xem là kết quả chính của H3.

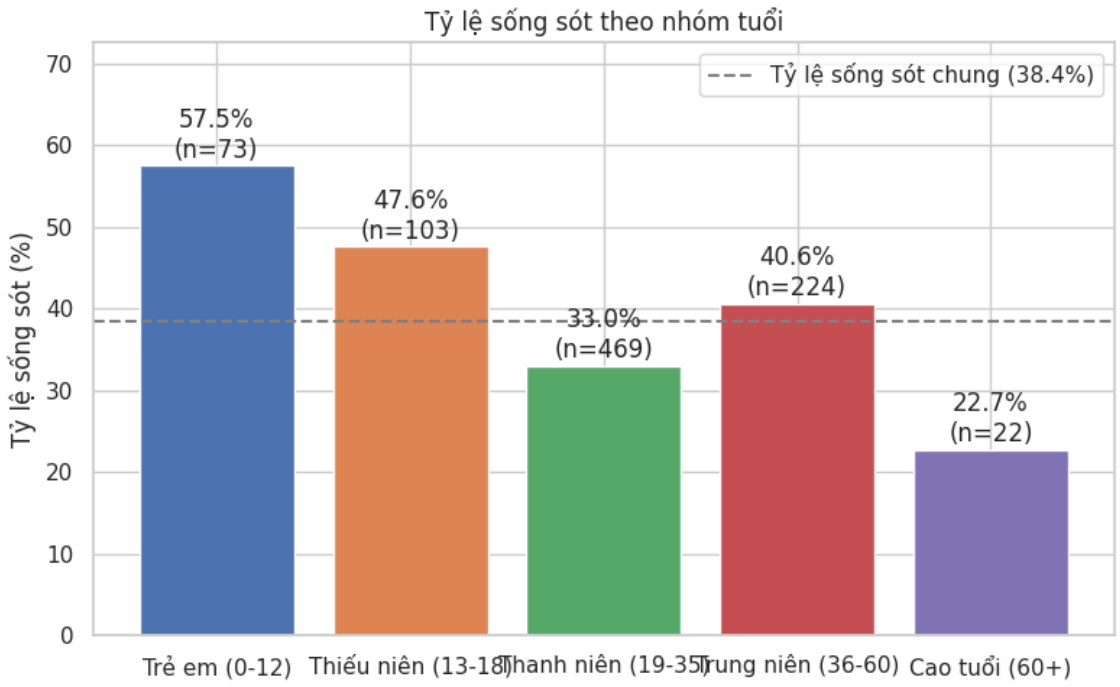
Kết quả chính của H3 trên dữ liệu tuổi gốc: Trong 891 hành khách, có 714 người có thông tin tuổi được ghi nhận. Kiểm định Mann-Whitney cho p = 0,160, chưa đủ bằng chứng cho thấy phân phối tuổi khác biệt có ý nghĩa thống kê giữa hai nhóm sống sót và tử vong ở mức 5%. Kiểm định Chi-square theo nhóm tuổi cho p = 0,0138, cho thấy tỷ lệ sống sót không đồng nhất giữa các khoảng tuổi.

Tỷ lệ sống sót theo nhóm tuổi gốc lần lượt là: 0-12 tuổi 58,0%; 13-18 tuổi 42,9%; 19-35 tuổi 38,3%; 36-60 tuổi 40,0%; trên 60 tuổi 22,7%. Kết quả gợi ý khác biệt có thể tập trung ở một số nhóm tuổi, đặc biệt trẻ em và người cao tuổi, thay vì thể hiện thành sự dịch chuyển rõ rệt của toàn bộ phân phối tuổi.

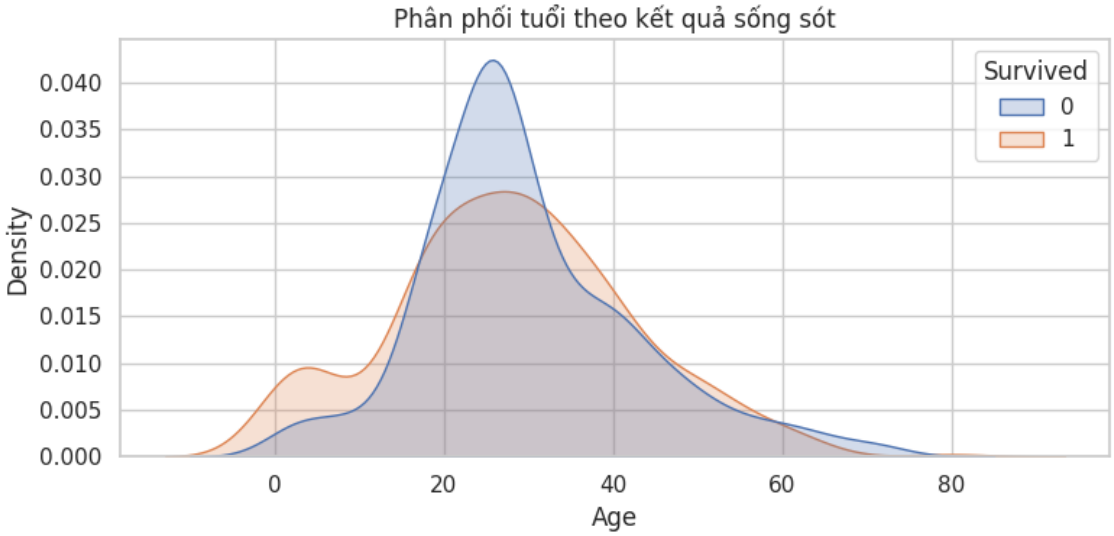
Hai kiểm định trả lời hai câu hỏi khác nhau: Chi-square đánh giá tỷ lệ sống sót có khác nhau giữa các nhóm tuổi hay không; Mann-Whitney so sánh phân phối thứ hạng tuổi giữa hai nhóm kết quả. Vì vậy, không nên gộp chúng thành kết luận đơn giản rằng tuổi có hoặc không có liên hệ.

Kiểm tra độ nhạy trên tuổi đã điền: Khi sử dụng toàn bộ 891 quan sát sau khi điền khuyết, Mann-Whitney cho $p = 0{,}216$ và Chi-square theo nhóm tuổi cho $p = 1{,}05 \times 10^{-4}$. Kết luận ở mức ý nghĩa 5% không đổi so với phân tích tuổi gốc: Mann-Whitney không có ý nghĩa thống kê, còn Chi-square có ý nghĩa thống kê. Tuy nhiên, p-value của Chi-square thay đổi đáng kể, cho thấy mức độ bằng chứng nhạy cảm với cách xử lý dữ liệu thiếu. Vì vậy, nhóm giữ phân tích trên 714 tuổi gốc làm kết quả chính và chỉ xem kết quả trên tuổi đã điền là kiểm tra độ nhạy.

Lưu ý về biểu đồ: KDE và biểu đồ tỷ lệ theo nhóm tuổi ở phần khám phá sử dụng biến Age đã điền để tận dụng toàn bộ quan sát; chúng có tính chất mô tả. Kết luận kiểm định chính của H3 vẫn dựa trên 714 tuổi gốc.

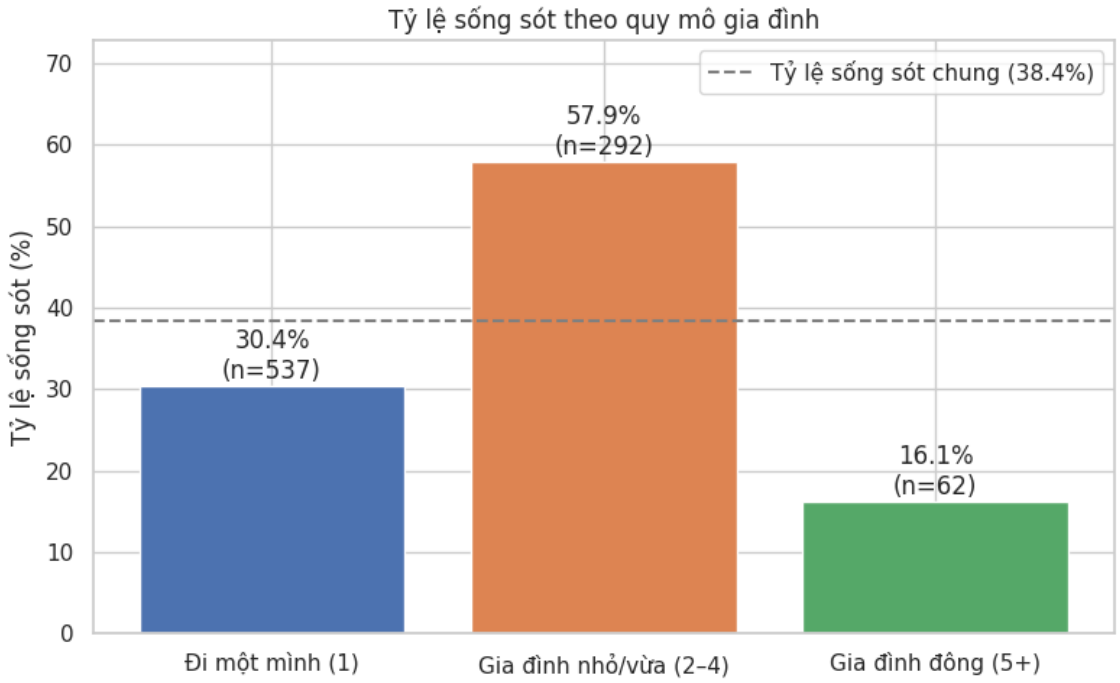


Hình 7. Tỷ lệ sống sót theo nhóm tuổi



Hình 8. Phân phối tuổi theo kết quả sống sót

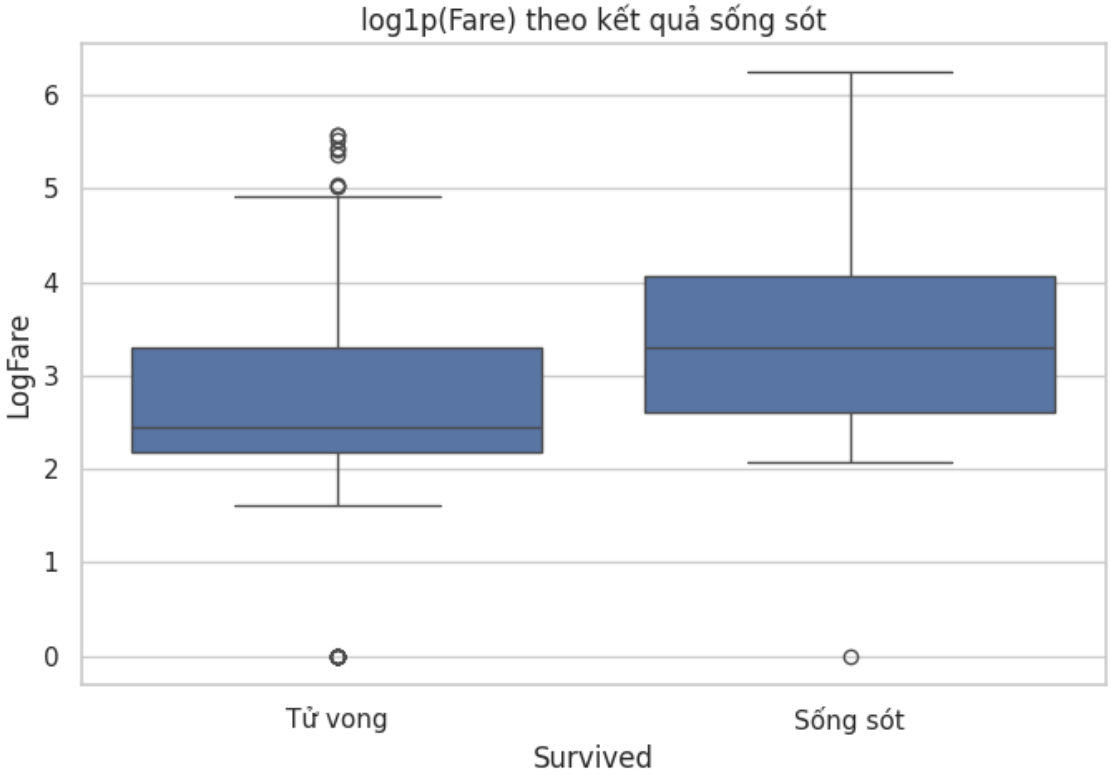
H4 - Quy mô gia đình



Hình 9. Tỷ lệ sống sót theo quy mô gia đình

Diễn giải: Sau khi gộp thành 3 nhóm, tỷ lệ sống sót là: đi một mình 30,4% (n = 537), gia đình nhỏ/vừa 2-4 người 57,9% (n = 292), gia đình đông 5+ người 16,1% (n = 62). Kiểm định Chi-square cho Chi2 = 74,54, $p \approx 6{,}5\times10^{-17}$, Cramér's V = 0,29, và mọi ô đều có tần suất kỳ vọng ≥ 5 (nhỏ nhất khoảng 24), nên kiểm định đủ điều kiện. Kết quả ủng hộ H4: gia đình nhỏ/vừa có tỷ lệ sống sót cao hơn rõ rệt. Khi chưa gộp (9 nhóm), Chi2 = 80,67 nhưng 5/18 ô có tần suất kỳ vọng dưới 5 nên kém tin cậy hơn. Nhóm gia đình đông chỉ có 62 người nên cần thận trọng; đây là mối liên hệ quan sát được, chưa chứng minh nguyên nhân.

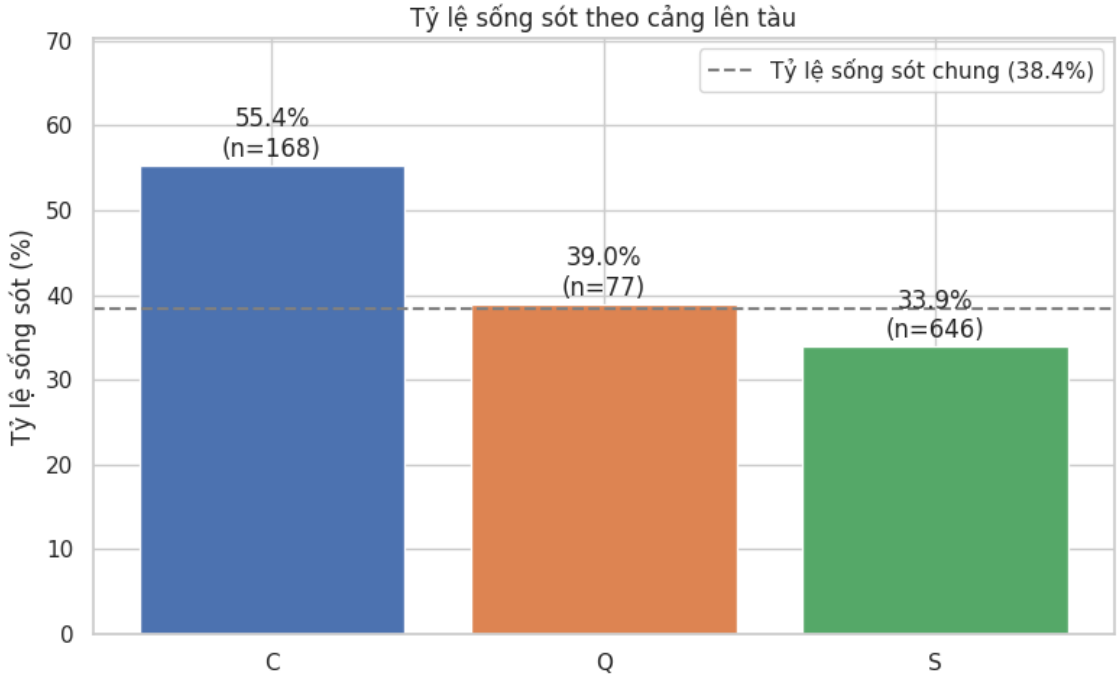
H5 - Giá vé



Hình 10. Phân phối giá vé (log1p) theo tình trạng sống sót

Diễn giải: Giá vé trung vị của nhóm sống sót là 26,0, cao hơn nhóm không sống sót (10,5); kiểm định Mann-Whitney cho p-value = $4{,}55 \times 10^{-22}$. Kết quả cho thấy phân phối giá vé khác biệt có ý nghĩa thống kê giữa hai nhóm. Tuy nhiên, Fare có liên hệ chặt với Pclass nên không thể xem giá vé là yếu tố độc lập nếu chưa kiểm soát hạng vé và các biến khác.

H6 - Cảng lên tàu và biến gây nhiễu



Hình 11. Tỷ lệ sống sót theo cảng lên tàu

Diễn giải: Cảng C có tỷ lệ sống sót quan sát được cao nhất, nhưng cơ cấu hạng vé tại cảng này cũng khác: khoảng 50,6% hành khách lên tàu tại C thuộc hạng 1, so với 20,0% tại S và 2,6% tại Q. Vì vậy, khác biệt tỷ lệ sống sót theo cảng có thể chịu ảnh hưởng của cơ cấu hạng vé và các yếu tố liên quan. Không nên kết luận bản thân cảng lên tàu làm tăng khả năng sống sót.

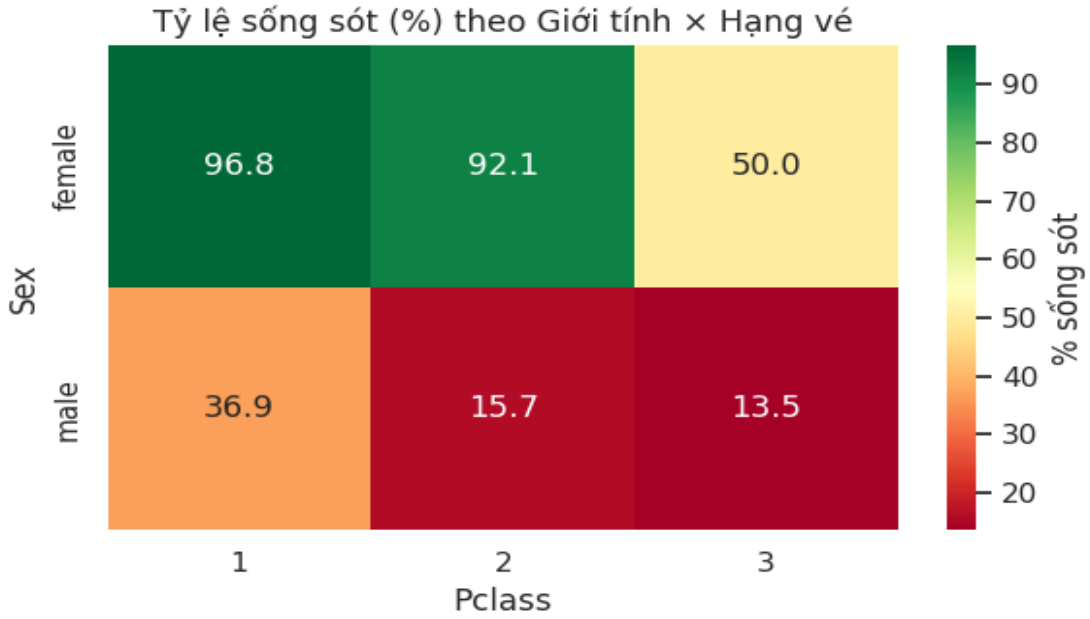
Tổng hợp kết quả kiểm định giả thuyết

Bảng 2. Tổng hợp kết quả kiểm định giả thuyết

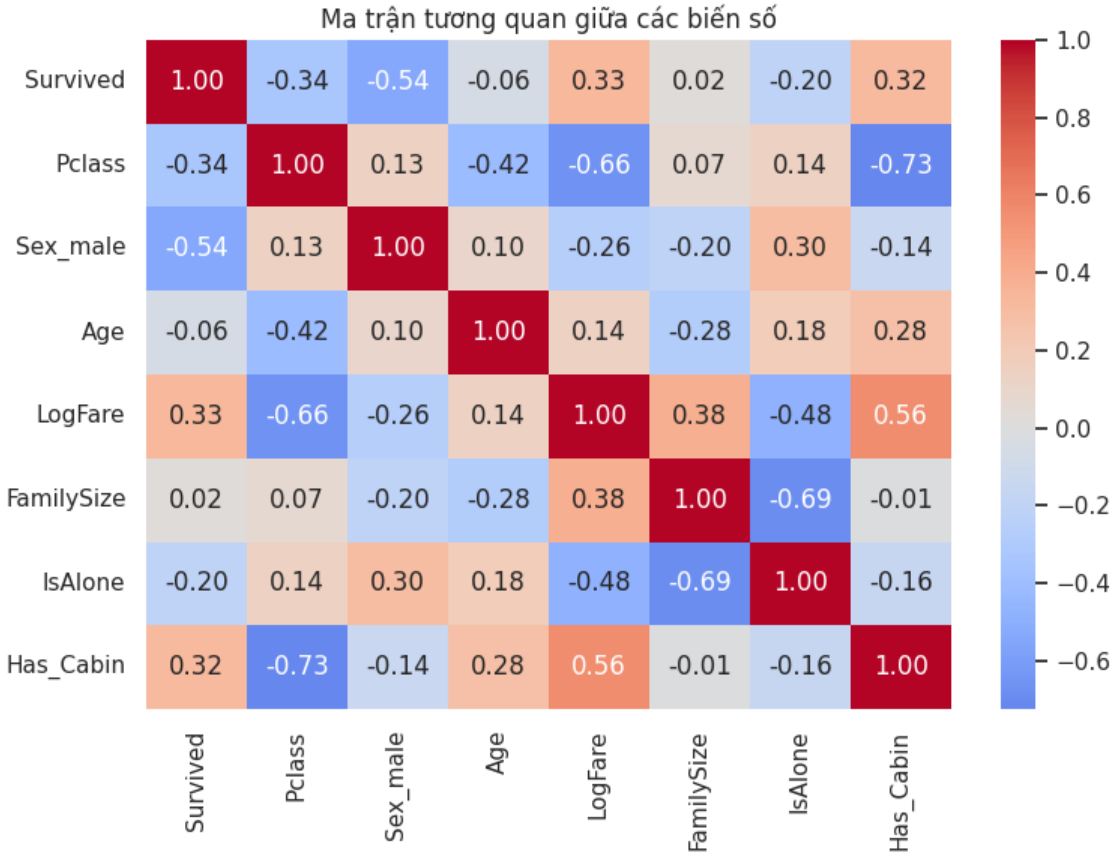
Giả thuyết	Phương pháp	Kết quả chính	Cỡ ảnh hưởng / lưu ý	Kết luận
H1 - Giới tính	Chi-square	$p = 1{,}20 \times 10^{-58}$	Cramér's V = 0,541	Có mối liên hệ; nữ có tỷ lệ sống sót cao hơn trong mẫu
H2 - Hạng vé	Chi-square	$p = 4{,}55 \times 10^{-23}$	Cramér's V = 0,340	Có mối liên hệ; tỷ lệ giảm từ hạng 1 đến hạng 3
H3 - Tuổi	Chi-square và Mann-Whitney trên 714 tuổi gốc	p = 0,0138 và p = 0,160	Hai kiểm định trả lời hai câu hỏi khác nhau	Có khác biệt giữa một số nhóm tuổi; chưa thấy khác biệt phân phối tuổi tổng thể theo Mann-Whitney
H4 - Quy mô gia đình	Chi-square	$p = 6{,}52 \times 10^{-17}$	Cramér's V = 0,289	Có mối liên hệ; nhóm 2-4 người có tỷ lệ cao nhất
H5 - Giá vé	Mann-Whitney U	$p = 4{,}55 \times 10^{-22}$	Trung vị: 26,0 so với 10,5	Phân phối Fare khác biệt giữa hai nhóm
H6 - Cảng lên tàu	Chi-square	$p = 2{,}30 \times 10^{-6}$	Cramér's V = 0,171; cơ cấu Pclass khác nhau giữa cảng	Có mối liên hệ, nhưng có khả năng chịu ảnh hưởng của cơ cấu hạng vé

Cách đọc kết quả: p-value nhỏ hơn 0,05 cho thấy có bằng chứng thống kê về khác biệt/mối liên hệ theo giả thuyết kiểm định; p-value không đo độ lớn hay tầm quan trọng thực tế của khác biệt. Cramér's V được dùng bổ sung cho các kiểm định Chi-square. Các kiểm định có tính khám phá và được thực hiện trên cùng một tập dữ liệu; nhóm chưa hiệu chỉnh p-value cho nhiều phép kiểm định, do đó các kết quả cần được diễn giải thận trọng.

Tương tác Giới tính × Hạng vé và ma trận tương quan



Hình 12. Tỷ lệ sống sót (%) theo Giới tính × Hạng vé



Hình 13. Ma trận tương quan giữa các biến số

Diễn giải: Heatmap giới tính × hạng vé cho phép quan sát đồng thời hai đặc điểm thay vì phân tích từng biến riêng lẻ. Khi đọc biểu đồ, cần so sánh các ô trong cùng một giới tính và giữa hai giới tính ở cùng hạng vé; đồng thời chú ý cỡ mẫu của từng nhóm nếu có bảng tần suất đi kèm. Nếu nhóm nữ có tỷ lệ sống sót cao hơn nhóm nam ở nhiều hạng vé, điều đó cho thấy khác biệt giới tính vẫn hiện diện khi phân tầng theo hạng vé, nhưng chưa thay thế được mô hình điều chỉnh nhiều biến.

Ma trận tương quan chỉ đo mức độ liên hệ tuyến tính giữa các biến số đã mã hóa. Dấu dương/âm thể hiện chiều đồng biến/nghịch biến, còn trị tuyệt đối càng lớn thể hiện liên hệ tuyến tính càng rõ trong mẫu. Các biến Pclass, LogFare và Has_Cabin có thể cùng phản ánh một phần điều kiện/hạng vé, do đó tương quan không nên được hiểu là tác động độc lập. Nhóm sử dụng hồi quy logistic nhiều biến ở phần tiếp theo để xem xét mối liên hệ có điều kiện.

3.2 Hồi quy logistic nhiều biến (kiểm soát đồng thời nhiều yếu tố)

Các kiểm định ở trên xem xét mối liên hệ giữa từng biến giải thích và tình trạng sống sót. Hồi quy logistic nhiều biến được sử dụng để xem xét mối liên hệ có điều kiện giữa từng đặc điểm và khả năng sống sót khi đồng thời đưa các yếu tố khác vào mô hình. Kết quả được trình bày dưới dạng Odds Ratio (OR). OR lớn hơn 1 biểu thị odds sống sót cao hơn, OR nhỏ hơn 1 biểu thị odds thấp hơn so với nhóm tham chiếu, trong điều kiện các biến khác không đổi. OR không phải là mức thay đổi trực tiếp của xác suất sống sót.

Diễn giải hồi quy đa biến: Bảng kết quả trình bày hệ số, Odds Ratio (OR), khoảng tin cậy 95% và p-value. Nhóm tham chiếu là nữ, hạng vé 1 và cảng C. OR lớn hơn 1 biểu thị odds sống sót cao hơn; OR nhỏ hơn 1 biểu thị odds thấp hơn, trong điều kiện các biến còn lại không đổi. OR không phải là mức thay đổi trực tiếp của xác suất.

Các kết quả đáng chú ý:

- Giới tính: Sex_male có OR = 0,067 (KTC 95%: 0,045-0,100; p < 0,001). Khi giữ các biến khác không đổi, odds sống sót của nam bằng khoảng 6,7% odds của nữ trong mô hình.
- Hạng vé: so với hạng 1, hạng 2 có OR = 0,458 (KTC 95%: 0,241-0,871; p = 0,017), còn hạng 3 có OR = 0,146 (KTC 95%: 0,071-0,303; p < 0,001). Kết quả cho thấy odds sống sót ước lượng thấp hơn ở các hạng vé thấp hơn.
- Tuổi: OR = 0,957 mỗi một năm tuổi (KTC 95%: 0,942-0,973; p < 0,001). Theo dạng mô hình hiện tại, tuổi tăng thêm một năm gắn với odds sống sót thấp hơn khoảng 4,3%, khi các biến khác không đổi.
- Quy mô gia đình: OR = 0,725 cho mỗi một đơn vị tăng của FamilySize (KTC 95%: 0,620-0,848; p < 0,001). Cần lưu ý giả định tuyến tính trên log-odds; quan hệ thực tế có thể không tuyến tính, như kết quả phân tích nhóm gia đình đã gợi ý.

- Giá vé: LogFare có OR = 1,454 (KTC 95%: 1,045-2,023; p = 0,026). Kết quả có ý nghĩa ở mức 5%, nhưng cần thận trọng vì Fare có thông tin chồng lấn với Pclass.
- Cảng lên tàu: Embarked_S (p = 0,123) và Embarked_Q (p = 0,649) chưa có bằng chứng thống kê về khác biệt so với cảng C ở mức 5%; khoảng tin cậy của OR đều chứa 1.

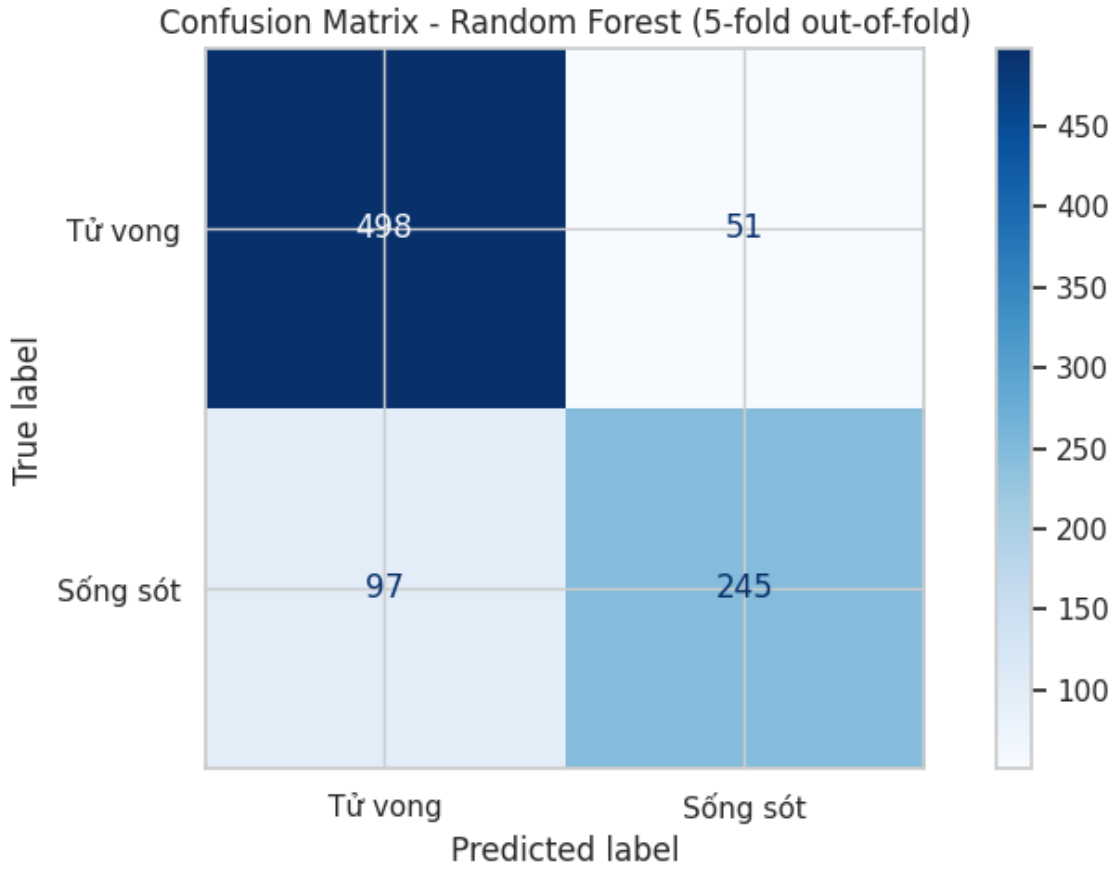
Mô hình giả định tác động tuyến tính trên log-odds đối với Age, FamilySize và LogFare. Nếu muốn diễn giải sâu hơn, cần kiểm tra dạng hàm và khả năng tương tác. Kết quả hồi quy là mối liên hệ có điều kiện theo các biến đã đưa vào mô hình, không phải xác suất sống sót trực tiếp và không chứng minh quan hệ nhân quả.

3.3. Xây dựng mô hình dự báo cơ sở

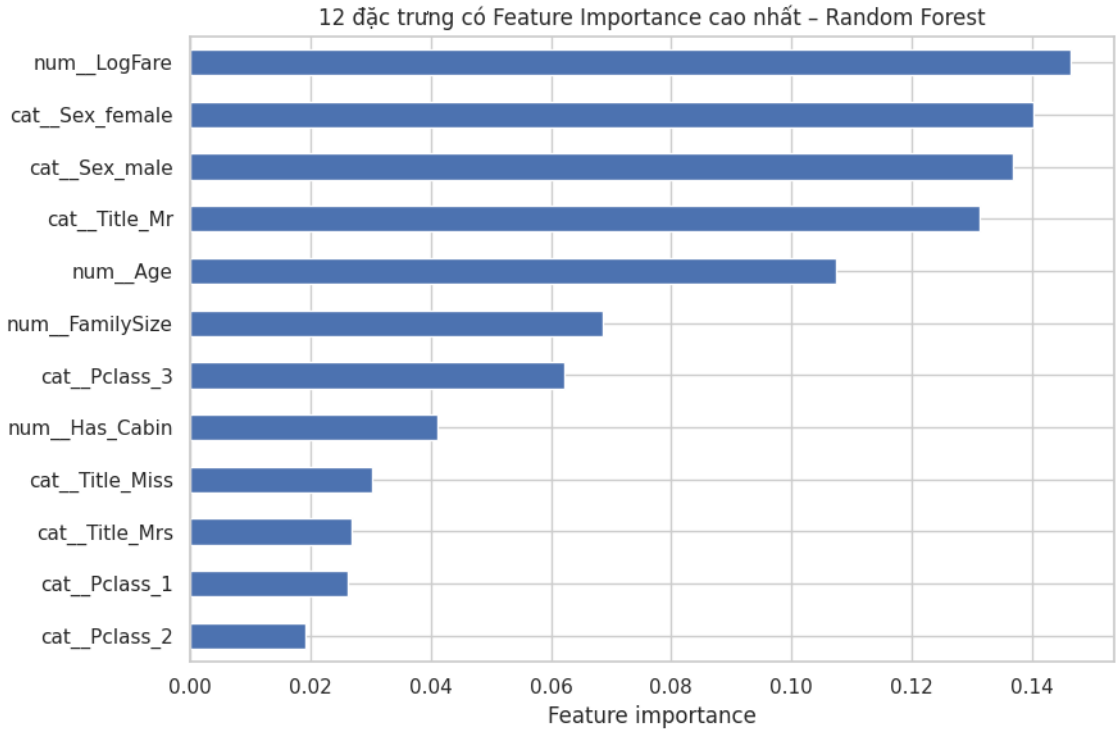
Nhóm so sánh hai thuật toán bằng Stratified 5-fold Cross Validation:

- Logistic Regression: mô hình tuyến tính, dễ giải thích và phù hợp làm mô hình cơ sở.
- Random Forest: mô hình tổ hợp cây quyết định, có thể nắm bắt quan hệ phi tuyến và tương tác giữa các đặc trưng.

Mục tiêu không chỉ là tối đa hóa Accuracy mà còn xem xét khả năng nhận diện nhóm sống sót, thể hiện qua Precision, Recall, F1-score và ROC-AUC. Tất cả bước điền khuyết, mã hóa và chuẩn hóa được đặt trong Pipeline để hạn chế Data Leakage.



Hình 14. Ma trận nhầm lẫn của Random Forest (out-of-fold)



Hình 15. Mười hai đặc trưng quan trọng nhất theo Random Forest

Diễn giải kết quả đánh giá mô hình: Kết quả kiểm định chéo phân tầng 5-fold:

Bảng 3. Kết quả đánh giá mô hình bằng Stratified 5-fold Cross Validation

Chỉ số	Logistic Regression	Random Forest
Accuracy	0,824 ± 0,011	0,834 ± 0,016
Precision	0,785 ± 0,018	0,828 ± 0,026
Recall	0,745 ± 0,032	0,716 ± 0,028
ROC-AUC	0,876 ± 0,017	0,882 ± 0,022
F1-score	0,764 ± 0,018	0,768 ± 0,023

Baseline Accuracy nếu luôn dự đoán lớp đa số (không sống sót) là 0,616. Cả hai mô hình đều cải thiện đáng kể so với baseline. Random Forest nhỉnh hơn về Accuracy, Precision, ROC-AUC và F1-score; Logistic Regression có Recall cao hơn, nghĩa là nhận diện được tỷ lệ hành khách sống sót thực tế lớn hơn trong kết quả dự đoán out-of-fold.

Vì chênh lệch giữa hai mô hình tương đối nhỏ, không nên khẳng định Random Forest vượt trội toàn diện. Nhóm sử dụng Random Forest để tạo dự báo trên test trong bài thực hành vì Accuracy và ROC-AUC trung bình cao hơn; nếu ưu tiên giảm bỏ sót người sống sót, Logistic Regression cũng là lựa chọn đáng cân nhắc. Chưa có kiểm định thống kê riêng để kết luận chênh lệch hiệu năng giữa hai mô hình có ý nghĩa.

Precision cho biết trong số hành khách được dự đoán sống sót, tỷ lệ dự đoán đúng là bao nhiêu; Recall cho biết mô hình nhận diện được bao nhiêu phần trăm hành khách thực sự sống sót; F1-score cân bằng Precision và Recall. ROC-AUC đo khả năng phân biệt hai lớp trên nhiều ngưỡng dự đoán. Confusion Matrix và Classification Report được tính từ dự đoán out-of-fold, tức mỗi hành khách được dự đoán bởi mô hình không huấn luyện trên fold chứa hành khách đó.

Feature Importance của Random Forest được tính sau khi fit mô hình trên toàn bộ train. Đây là thước đo mức độ hữu ích tương đối của đặc trưng trong mô hình, không thể hiện chiều tác động và không chứng minh quan hệ nhân quả. Sex_female và Sex_male là hai biến mã hóa của cùng thuộc tính giới tính; không nên xem chúng là hai yếu tố độc lập. Khi cần diễn giải theo biến gốc, cần tổng hợp tầm quan trọng của các biến mã hóa cùng một thuộc tính hoặc dùng permutation importance/SHAP.

Sau đánh giá, Random Forest được fit trên toàn bộ train và áp dụng lên 418 quan sát trong test.csv để tạo titanic_predictions.csv. Vì test không có nhãn Survived, nhóm không tính Accuracy, Precision, Recall, F1-score hoặc ROC-AUC trên tập này.

Nhận xét và đánh giá giai đoạn 3

Phần phân tích đã kiểm tra sáu giả thuyết bằng các phương pháp phù hợp với dạng biến: Chi-square cho biến phân loại và Mann-Whitney U cho biến liên tục. Các biểu đồ cột thể hiện tỷ lệ sống sót theo nhóm kèm cỡ mẫu; boxplot và phân phối mật độ hỗ trợ so sánh biến liên tục; heatmap giúp quan sát tương tác giữa giới tính và hạng vé; ma trận tương quan tóm tắt liên hệ tuyến tính giữa các biến số. Mỗi nhóm biểu đồ đều được gắn với một câu hỏi phân tích và có phần diễn giải ngay sau kết quả.

Các phát hiện nổi bật trong mẫu gồm: tỷ lệ sống sót của nữ cao hơn nam; tỷ lệ sống sót giảm theo hạng vé từ hạng 1 đến hạng 3; nhóm gia đình 2-4 người có tỷ lệ sống sót cao hơn nhóm đi một mình và nhóm gia đình đông; giá vé trung vị của nhóm sống sót cao hơn nhóm tử vong. Với tuổi, kiểm định chính trên 714 quan sát có tuổi gốc cho thấy Chi-square theo nhóm tuổi có ý nghĩa thống kê ($p = 0,0138$), trong khi Mann-Whitney trên tuổi liên tục không có ý nghĩa ở mức 5% ($p = 0,160$). Hai kiểm định trả lời hai câu hỏi khác nhau. Kết quả trên tuổi đã điền được dùng làm kiểm tra độ nhạy và cho thấy p-value Chi-square thay đổi, vì vậy cần thận trọng khi diễn giải.

Đối với cảng lên tàu, có sự khác biệt tỷ lệ sống sót giữa các cảng, nhưng cơ cấu hạng vé giữa các cảng cũng khác nhau. Vì vậy, chưa thể quy khác biệt này cho bản thân cảng lên tàu. Hồi quy logistic nhiều biến bổ sung góc nhìn có điều kiện khi đồng thời xem xét giới tính, tuổi, quy mô gia đình, giá vé, hạng vé và cảng lên tàu.

Hai mô hình dự báo được đánh giá bằng Stratified 5-fold Cross Validation. Việc báo cáo Accuracy, Precision, Recall, F1-score, ROC-AUC cùng Confusion Matrix giúp đánh giá cân bằng hơn trên dữ liệu có tỷ lệ hai lớp khác nhau. Random Forest nhỉnh hơn ở một số chỉ số nhưng Logistic Regression có Recall cao hơn; do đó lựa chọn mô hình phụ thuộc mục tiêu đánh giá. Dự đoán trên test.csv chỉ là kết quả áp dụng mô hình, không phải kết quả đánh giá vì không có nhãn thực tế.

Kết luận giai đoạn 3: dữ liệu cho thấy nhiều mối liên hệ thống kê đáng chú ý giữa đặc điểm hành khách và tình trạng sống sót. Tuy nhiên, đây là dữ liệu quan sát lịch sử; các kiểm định và mô hình dự báo không đủ cơ sở để khẳng định quan hệ nhân quả. Các nhận định phải được đặt trong phạm vi mẫu, phương pháp kiểm định và giới hạn của dữ liệu.

GIAI ĐOẠN 4: ĐÁNH GIÁ TÁC ĐỘNG VÀ KHUYẾN NGHỊ

4.1. Các phát hiện chuyên môn nổi bật

1. Giới tính: nữ có tỷ lệ sống sót khoảng 74,2%, trong khi nam khoảng 18,9%; Cramér's V = 0,541. Đây là mối liên hệ mạnh nhất trong các phân tích đơn biến.
2. Hạng vé: tỷ lệ sống sót lần lượt khoảng 63,0%, 47,3% và 24,2% ở hạng 1, 2 và 3; Cramér's V = 0,340.
3. Tuổi: kết quả phụ thuộc cách biểu diễn. Trên 714 quan sát có tuổi gốc, Chi-square theo nhóm tuổi có p = 0,0138, trong khi Mann-Whitney trên tuổi liên tục có p = 0,160.
4. Quy mô gia đình: nhóm 2-4 người có tỷ lệ sống sót 57,9%, cao hơn nhóm đi một mình (30,4%) và gia đình đông từ 5 người (16,1%); Cramér's V = 0,289.
5. Giá vé: trung vị Fare của nhóm sống sót là 26,0, so với 10,5 ở nhóm tử vong; Mann-Whitney $p = 4{,}55 \times 10^{-22}$. Fare có liên hệ với Pclass nên không nên diễn giải độc lập.
6. Cảng lên tàu: có mối liên hệ thống kê với tình trạng sống sót ($p = 2{,}301 \times 10^{-6}$; Cramér's V = 0,171), nhưng cơ cấu hạng vé giữa các cảng khác nhau rõ rệt.
7. Mô hình dự báo: Random Forest đạt Accuracy 0,834 và ROC-AUC 0,882; Logistic Regression đạt Accuracy 0,824 và ROC-AUC 0,876, nhưng Recall của Logistic Regression cao hơn (0,745 so với 0,716). Không mô hình nào vượt trội trên tất cả chỉ số.

4.2. Đánh giá tác động và hàm ý quản trị

Dữ liệu lịch sử cho thấy kết quả sống sót khác nhau đáng kể giữa các nhóm hành khách. Những khác biệt này có thể phản ánh sự khác nhau về vị trí, khả năng tiếp cận lối thoát hiểm, điều kiện di chuyển, thông tin được tiếp nhận và cách tổ chức sơ tán. Tuy nhiên, bộ dữ liệu không ghi nhận đầy đủ các yếu tố này nên không thể xác định nguyên nhân trực tiếp. Vì vậy, nhóm chuyển các phát hiện thành hàm ý để rà soát và cải thiện hệ thống an toàn, không coi chúng là bằng chứng nhân quả.

Bảng 4. Phát hiện từ dữ liệu, hàm ý quản trị và giới hạn diễn giải

Phát hiện từ dữ liệu	Hàm ý quản trị	Giới hạn diễn giải
Tỷ lệ sống sót khác biệt lớn theo giới tính	Rà soát quy trình sơ tán để bảo đảm mọi hành khách được tiếp cận hướng dẫn và phương tiện cứu sinh công bằng	Không suy ra giới tính tự nó gây ra khác biệt
Tỷ lệ sống sót giảm theo hạng vé	Bảo đảm lối thoát hiểm, thông tin và hỗ trợ cứu hộ không phụ thuộc hạng vé	Pclass có thể đại diện đồng thời cho vị trí và điều kiện tiếp cận

Phát hiện từ dữ liệu	Hàm ý quản trị	Giới hạn diễn giải
	hay thu nhập	
Trẻ em có tỷ lệ sống sót cao hơn một số nhóm tuổi; người cao tuổi có tỷ lệ thấp hơn trong mẫu	Có phương án hỗ trợ trẻ em, người cao tuổi và người cần trợ giúp khi di chuyển	Dữ liệu không có thông tin sức khỏe hoặc khả năng di chuyển
Gia đình 2-4 người có tỷ lệ sống sót cao hơn nhóm đi một mình và nhóm đông	Thiết kế hướng dẫn cho nhóm đi cùng; có phương án kiểm đếm và hỗ trợ người đi một mình	Không kết luận quy mô gia đình là nguyên nhân trực tiếp
Cabin thiếu nhiều thông tin	Cải thiện quản trị danh sách hành khách và vị trí cabin trong hệ thống an toàn	Dữ liệu thiếu không chứng minh cabin không tồn tại

4.3. Khuyến nghị ứng dụng thực tế

Khuyến nghị 1 - Chuẩn hóa quy trình sơ tán công bằng và dễ tiếp cận.

Xây dựng hướng dẫn thoát hiểm thống nhất cho mọi hạng vé và khu vực trên tàu. Bảng chỉ dẫn cần dễ nhìn, dễ hiểu, có phương án truyền tải bằng hình ảnh, âm thanh và nhiều ngôn ngữ khi cần. Định kỳ rà soát để bảo đảm hành khách ở khu vực xa boong hoặc khó tiếp cận vẫn nhận được thông tin kịp thời.

Khuyến nghị 2 - Thiết lập cơ chế hỗ trợ hành khách cần trợ giúp.

Khi làm thủ tục lên tàu, có thể ghi nhận ở mức cần thiết các nhu cầu hỗ trợ tự nguyện như trẻ em đi cùng người giám hộ, người cao tuổi hoặc người hạn chế khả năng di chuyển. Phân công nhân sự hỗ trợ theo khu vực, tổ chức diễn tập và xây dựng phương án trợ giúp mà không làm lộ thông tin cá nhân không cần thiết.

Khuyến nghị 3 - Tổ chức diễn tập và kiểm tra khả năng tiếp cận thực tế.

Không chỉ kiểm tra sự tồn tại của lối thoát hiểm, đơn vị vận hành cần đo thời gian tiếp cận, kiểm tra tình trạng biển chỉ dẫn, hệ thống phát thanh, đèn sự cố và khả năng di chuyển của hành khách trong điều kiện mô phỏng. Sau mỗi đợt diễn tập, ghi nhận điểm nghẽn và giao trách nhiệm khắc phục.

Khuyến nghị 4 - Nâng cao chất lượng dữ liệu an toàn hành khách.

Duy trì danh sách hành khách, thông tin cabin và số lượng người theo khu vực ở mức chính xác, cập nhật. Dữ liệu cần được phân quyền truy cập, bảo vệ quyền riêng tư, có bản sao dự

phòng và phương án sử dụng khi mất kết nối. Mục tiêu là hỗ trợ kiểm đếm, liên lạc và tổ chức sơ tán, không thu thập dữ liệu vượt quá nhu cầu an toàn.

Khuyến nghị 5 - Chỉ sử dụng mô hình dự báo như công cụ hỗ trợ nghiên cứu.

Mô hình Titanic được xây dựng trên dữ liệu lịch sử nhỏ và thiếu nhiều thông tin quan trọng, do đó không phù hợp để tự động quyết định thứ tự cứu hộ. Trước khi ứng dụng bất kỳ mô hình nào vào vận hành, cần kiểm định trên dữ liệu độc lập, đánh giá sai số theo từng nhóm, kiểm tra độ hiệu chỉnh và có người chịu trách nhiệm ra quyết định. Nguyên tắc cứu hộ phải dựa trên quy trình an toàn, mức độ nguy cấp và nhu cầu trợ giúp, không dựa máy móc vào dự đoán thống kê.

Một số chỉ tiêu quản trị có thể theo dõi (đề xuất):

- Tỷ lệ hành khách được tiếp cận hướng dẫn an toàn trước khi khởi hành.
- Tỷ lệ nhân viên hoàn thành diễn tập sơ tán định kỳ.
- Tỷ lệ khu vực/cabin được kiểm tra khả năng tiếp cận lối thoát hiểm.
- Thời gian phát thông báo khẩn cấp và thời gian kiểm đếm hành khách trong diễn tập.
- Tỷ lệ sự cố về biển chỉ dẫn, phát thanh hoặc chiếu sáng được khắc phục đúng hạn.

Các chỉ tiêu trên là gợi ý quản trị để đơn vị vận hành tự thiết lập mục tiêu phù hợp; chúng không phải số liệu đã được đo lường trong bộ dữ liệu Titanic.

4.4. Hạn chế của nghiên cứu và hướng phát triển

Hạn chế

1. Quy mô và phạm vi dữ liệu: tập train chỉ có 891 hành khách trên một chuyến tàu, không đại diện cho mọi tai nạn hàng hải.
2. Dữ liệu thiếu: Cabin thiếu 77,10% và Age thiếu 19,87%; việc điền khuyết có thể ảnh hưởng đến phân phối và kết quả kiểm định.
3. Thiếu biến quan trọng: dữ liệu không mô tả đầy đủ vị trí thực tế của hành khách khi tai nạn xảy ra, khoảng cách tới xuồng cứu sinh, tình trạng sức khỏe, thời điểm sơ tán hoặc hành vi trong tình huống khẩn cấp.
4. Nguy cơ biến gây nhiễu: Pclass, Fare, Cabin và Embarked có thể liên quan với nhau. Hồi quy nhiều biến chỉ kiểm soát được các biến đã quan sát và đưa vào mô hình.
5. Giới hạn suy luận: dữ liệu mang tính quan sát, nên mối liên hệ thống kê không chứng minh quan hệ nhân quả. Nhóm cũng chưa hiệu chỉnh p-value cho nhiều phép kiểm định.
6. Giới hạn mô hình: kiểm định chéo được thực hiện trên train; tập test Kaggle không có nhãn thật nên không thể xác minh hiệu năng cuối cùng trên test. Kết quả còn phụ thuộc vào cách chia fold, lựa chọn đặc trưng và tham số mô hình. Feature Importance của Random Forest không cho biết chiều tác động và có thể ưu tiên một số dạng đặc trưng.

Hướng phát triển

- Bổ sung dữ liệu từ nhiều sự cố hàng hải để tăng tính đại diện.
- Thu thập thêm thông tin về vị trí cabin, khoảng cách tới xuồng cứu sinh, khả năng di chuyển, tình trạng sức khỏe và thời điểm sơ tán.
- Kiểm tra độ ổn định của mô hình bằng nhiều lần chia dữ liệu, nested cross-validation hoặc tập dữ liệu độc lập.
- Đánh giá thêm calibration, precision-recall trade-off và sai số theo từng nhóm hành khách.
- Sử dụng permutation importance hoặc SHAP để giải thích mô hình; kiểm tra thiên lệch và tính công bằng trước khi cân nhắc ứng dụng.
- Thử nghiệm thêm mô hình khác chỉ khi có đủ dữ liệu và thiết kế đánh giá phù hợp, tránh chạy theo độ phức tạp mà không cải thiện giá trị sử dụng.

Kết luận giai đoạn 4: nghiên cứu cung cấp một quy trình phân tích dữ liệu từ đánh giá chất lượng, làm sạch, kiểm định giả thuyết đến xây dựng mô hình dự báo. Giá trị ứng dụng nằm ở việc dùng bằng chứng dữ liệu để nhận diện những khác biệt cần được rà soát trong công tác an toàn, đồng thời không vượt quá giới hạn mà dữ liệu cho phép.

KẾT LUẬN CHUNG

Qua bốn giai đoạn, nhóm đã thực hiện quy trình khoa học dữ liệu tương đối đầy đủ: xác định nguồn và cấu trúc dữ liệu; đánh giá chất lượng và giá trị thiếu; xử lý dữ liệu bất thường theo ngữ cảnh; tạo đặc trưng; kiểm định giả thuyết; trực quan hóa; xây dựng và so sánh mô hình dự báo.

Kết quả cho thấy giới tính, hạng vé, quy mô gia đình, giá vé và cảng lên tàu có những mối liên hệ thống kê với tình trạng sống sót trong mẫu Titanic. Phân tích tuổi cho thấy kết quả phụ thuộc vào cách biểu diễn và xử lý dữ liệu thiếu, vì vậy nhóm ưu tiên kiểm định trên tuổi gốc. Mô hình Random Forest đạt Accuracy 0,834 và ROC-AUC 0,882 trong kiểm định chéo, nhưng Logistic Regression có Recall cao hơn; việc lựa chọn mô hình cần gắn với mục tiêu sử dụng.

Quan trọng nhất, kết quả phân tích không được diễn giải thành quan hệ nhân quả hoặc dùng để quyết định thứ tự cứu hộ trong thực tế. Các khuyến nghị được đề xuất theo hướng cải thiện khả năng tiếp cận thông tin, hỗ trợ hành khách cần trợ giúp, bảo đảm công bằng trong sơ tán và nâng cao chất lượng dữ liệu an toàn. Nghiên cứu cũng chỉ ra nhu cầu bổ sung dữ liệu độc lập và các biến phản ánh trực tiếp điều kiện sơ tán để tăng độ tin cậy của các phân tích tiếp theo.